

Quantitative Textanalyse 1: Stilometrie

Vorlesung Einführung in die Digital Humanities MSc Digital Humanities | Wintersemester 2020/21

Prof. Dr. Christof Schöch



1

Sitzungsüberblick

- 1. Quantitative Textanalyse: Überblick
- 2. Software im Überblick
- 3. Stilometrie (Textähnlichkeit)

(1) Quantitative Textanalyse: Überblick

Anwendungsbereiche

- Autorschaftsattribution
- Gattungsstilistik
- Netzwerkanalyse
- Inhaltsanalyse (Begriffe, Topics)
- Automatische Kartierung
- Extraktion von Zeitstrukturen
- Erkennung erzähltheoretischer Kategorien
- uvm.

Grundlegende Verfahren

- Suche nach Mustern
- Kontrastive Analyse
- Gruppen ähnlicher Texte entdecken
- Verteilungen und Entwicklungen finden
- Informationen explizit machen
- Dimensionsreduktion
- Texte klassifizieren

Perspektiven der digitalen Textanalyse

- Quantitative vs. qualitative Verfahren
- Analyseverfahren vs. Datenvisualisierung
- Grafische Benutzungsoberfläche (GUI) vs. Command Line Interface (CLI)
- Klassifikation vs. Clustering

(2) Software im Überblick

Natural Language Processing: NLTK

1 Using a Tagger

A part-of-speech tagger, or **POS-tagger**, processes a sequence of words, and attaches a part of speech tag to each word (don't forget to import nltk):

```
>>> text = word_tokenize("And now for something completely different")
>>> nltk.pos_tag(text)
[('And', 'CC'), ('now', 'RB'), ('for', 'IN'), ('something', 'NN'),
('completely', 'RB'), ('different', 'JJ')]
```

Here we see that and is CC, a coordinating conjunction; now and completely are RB, or adverbs; for is IN, a preposition; something is NN, a noun; and different is JJ, an adjective.

Note

NLTK provides documentation for each tag, which can be queried using the tag, e.g. nltk.help.upenn_tagset('RB'), or a regular expression, e.g. nltk.help.upenn_tagset('NN.*'). Some corpora have README files with tagset documentation, see nltk.corpus.???.readme(), substituting in the name of the corpus.

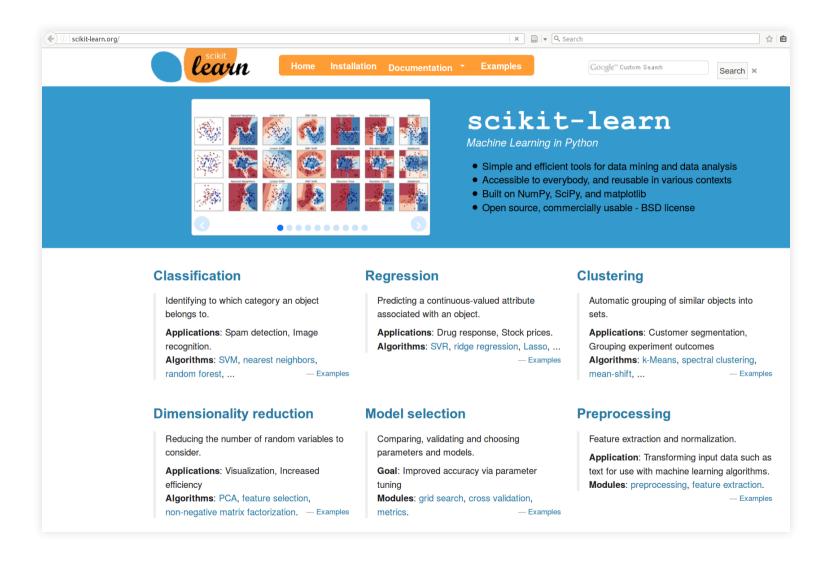
Let's look at another example, this time including some homonyms:

```
>>> text = word_tokenize("They refuse to permit us to obtain the refuse permit")
>>> nltk.pos_tag(text)
[('They', 'PRP'), ('refuse', 'VBP'), ('to', 'TO'), ('permit', 'VB'), ('us', 'PRP'),
('to', 'TO'), ('obtain', 'VB'), ('the', 'DT'), ('refuse', 'NN'), ('permit', 'NN')]
```

Notice that *refuse* and *permit* both appear as a present tense verb (VBP) and a noun (NN). E.g. *refUSE* is a verb meaning "deny," while *REFuse* is a noun meaning "trash" (i.e. they are not homophones). Thus, we need to know which word is being used in order to pronounce the text correctly. (For this reason, text-to-speech systems usually perform POS-tagging.)

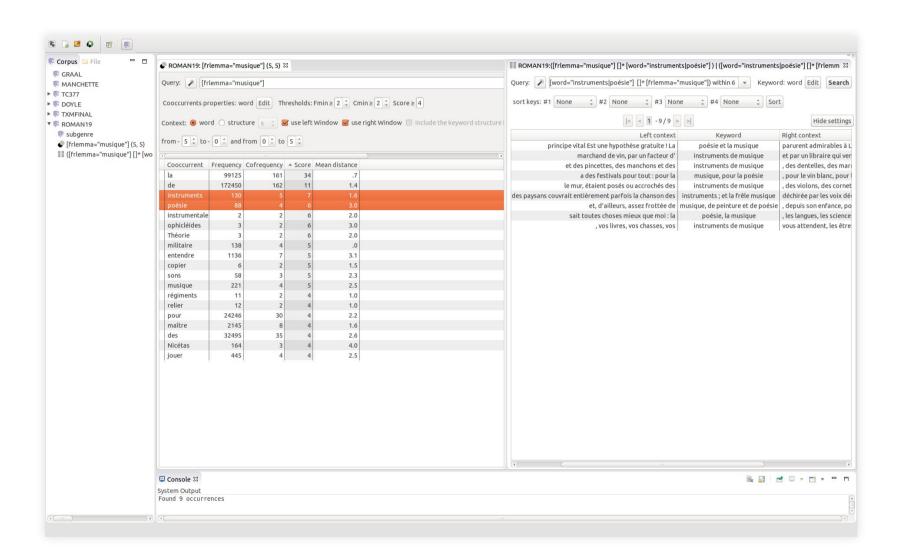
http://www.nltk.org; Alternativen: TreeTagger, spaCy

Maschinelles Lernen: scikit-learn (Python)



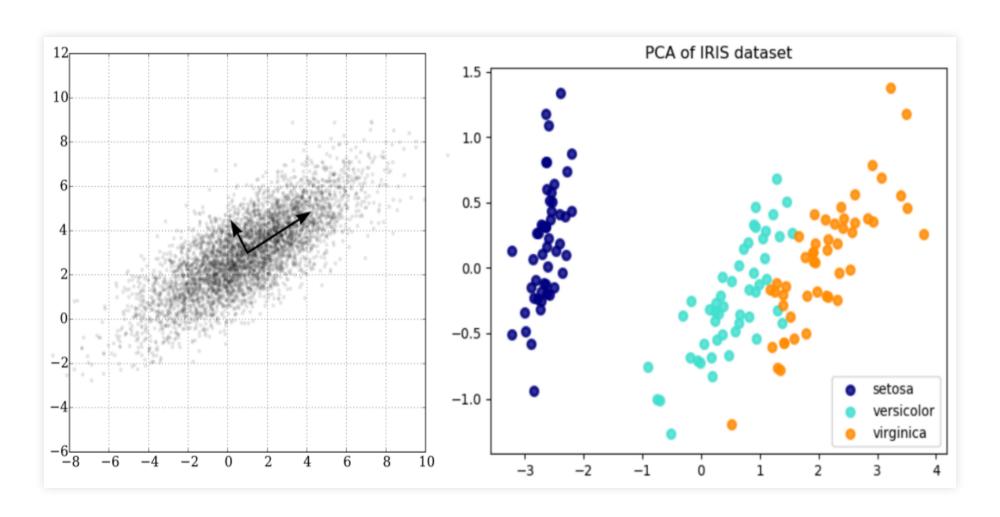
http://scikit-learn.org, Alternative: R

Korpusanalyse: TXM



http://textometrie.ens-lyon.fr; Alternative: Antconc

Principal Components Analysis



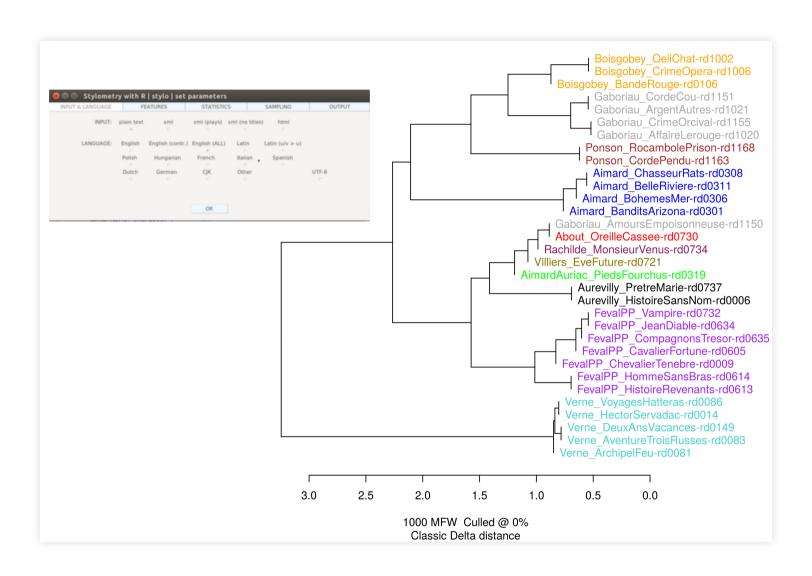
Diverse Tools: stylo, Python, etc.

Topic Modeling: MALLET

```
🙉 🖨 📵 christof@DELL: ~/Programs/mallet
christof@DELL:~$ cd Programs/mallet
christof@DELL:~/Programs/mallet$ bin/mallet import-dir --input /home/christof/Re
pos/clgs/polar/txt10d --output polar.mallet --keep-sequence --token-regex '\p{L
}[\p{L}\p{P}]*\p{L}' --remove-stopwords TRUE --stoplist-file stoplists/fr3.txt
Labels =
   /home/christof/Repos/clgs/polar/txt10d
christof@DELL:~/Programs/mallet$ bin/mallet train-topics --input polar.mallet -
-num-topics 30 --optimize-interval 200 --num-iterations 4000 --num-top-words 30
--word-topic-counts-file results/polar10d_words-by-topics.txt --output-state top
ic-state.gz --output-topic-keys results/polar-10d_topics-with-words.txt --output
-doc-topics results/polar10d topics-in-texts.txt --doc-topics-max 30
```

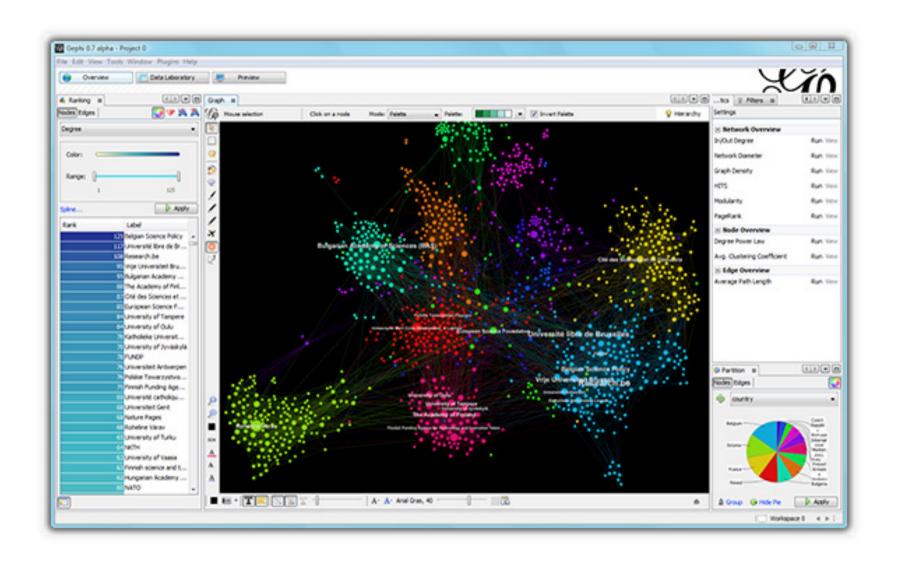
http://mallet.cs.umass.edu/topics.php; Alternative: gensim

Stilometrie: stylo for R



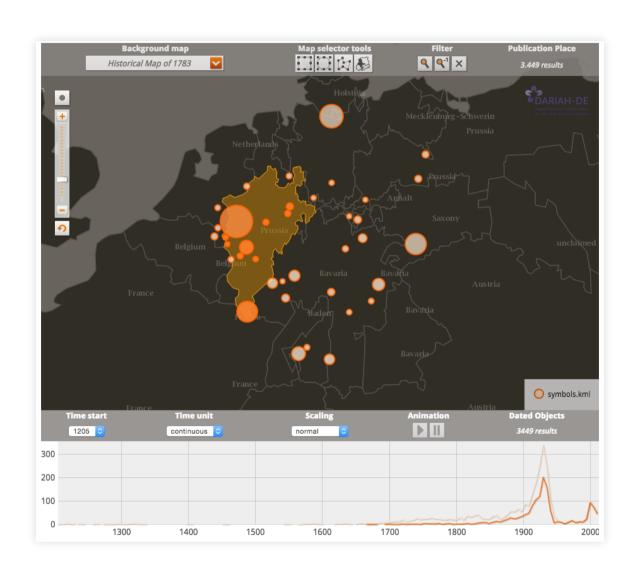
https://sites.google.com/site/computationalstylistics/

Netzwerkanalyse: Gephi



https://gephi.org/; Alternative: networkX

Kartierung: DARIAH Geobrowser



https://de.dariah.eu/geobrowser; Alternative: folium

(3) Stilometrische Autorschaftsattribution

Zwei Typen von ML

unüberwacht	überwacht
Clustering	Klassifikation
Bilden von Gruppen	Zuordnung zu Klassen
keine Klassen	vorher bekannte Klassen
ein Datensatz	Training/Test/Anwendung
eher explorativ	hypothesengeleitet
Evaluation möglich	Evaluation leicht
Topic Modeling PCA, CA	Annotation OCR, NER

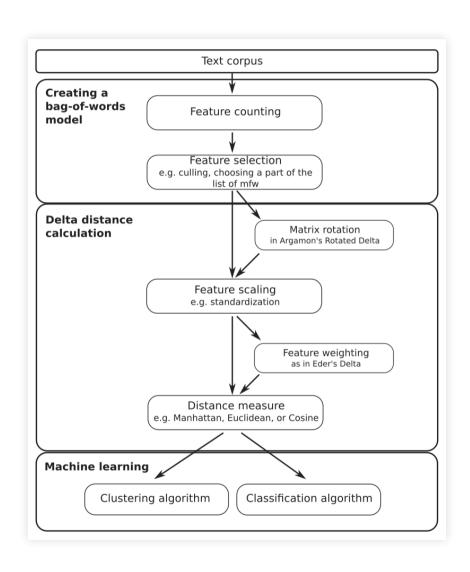
Stilometrie: Definition

Die Stilometrie ist eines von mehreren Verfahren, die dem Bereich der quantitativen Textanalyse zugerechnet werden können. Der Begriff Stilometrie bezeichnet dabei computergestützte Verfahren der Erhebung lexikalischer bzw. stilistischer Merkmale und ihrer Häufigkeiten in Texten, die Nutzung dieser Merkmale und Häufigkeiten als Indikatoren für die mehr oder weniger große Ähnlichkeit von Texten, sowie das Clustering oder die Klassifikation von Texten auf Grundlage dieser Ähnlichkeit.

Anwendungsfälle

- Shakespeare vs. Zeitgenossen
- J.K. Rowling, "The Cuckoo's Calling"
- Elena Ferrante
- Molière vs. Corneille
- uvm.

Stilometrie "step-by-step" (1)



Bildquelle: Steffen Pielström in Evert et al. 2017

Textsammlung (Metadaten)

	А	В	С	D	Е	F
1	idno	author	title	year	genre	form
2	tc0189	CorneilleP	Sertorius	1662	Tragédie	vers
3	tc0196	CorneilleP	ConqueteToison	1661	Tragédie	vers
4	tc0200	CorneilleT	Ariane	1672	Tragédie	vers
5	tc0222	CorneilleT	MortAchille	1673	Tragédie	vers
6	tc0226	CorneilleT	Stilicon	1660	Tragédie	vers
7	tc0656	RacineJ	Britannicus	1669	Tragédie	vers
8	tc0661	RacineJ	Phèdre	1677	Tragédie	vers

Drei Autoren: Thomas und Pierre Corneille sowie Racine

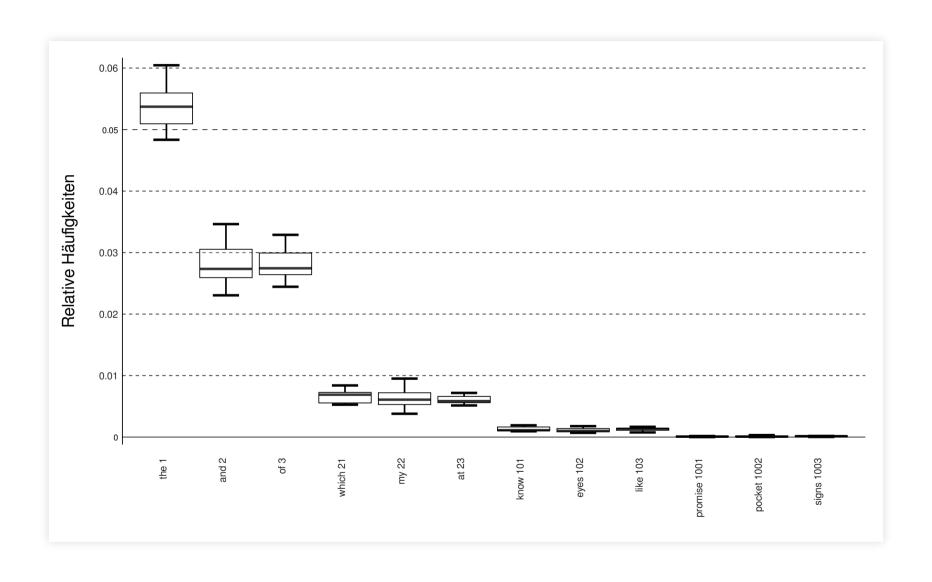
Relative Häufigkeiten

	А	В	С	D	E
1		CorneilleP_tc0189	CorneilleP_tc0196	CorneilleT_tc0222	CorneilleT_tc0226
2	de	3.5666666667	3.7785192533	3.4143340511	2.9700921039
3	et	2.7333333333	2.7640003607	1.9686250384	2.5302701025
4	vous	2.822222222	2.191360808	1.9686250384	1.3453378868
5	le	1.877777778	2.0290377852	2.4607812981	2.5613163614
6	à	2.1388888889	2.4844440436	2.159335589	2.2301562662
7	I	1.888888889	1.5826494725	2.0547523839	2.6803270206
8	que	1.894444444	1.8351519524	1.956321132	1.5937079582
9	je	1.9611111111	1.3797456939	1.531836358	1.3970816517
10	il	1.494444444	1.3707277482	1.6425715165	1.7127186174
11	un	1.388888889	1.4383623411	1.2488465088	1.6247542171
12	la	1.1611111111	1.5105059068	1.4026453399	1.3401635103
13	en	1.527777778	1.4248354225	1.3903414334	1.5109179344
14	qu	1.422222222	1.3617098025	1.5379883113	1.5057435579
15	les	1.2611111111	1.6322481739	1.1196554906	0.7709820967
16	d	1.3388888889	1.3662187754	1.1811750231	1.4591741695
17	est	1.1388888889	0.9604112183	1.4887726853	1.2470247335

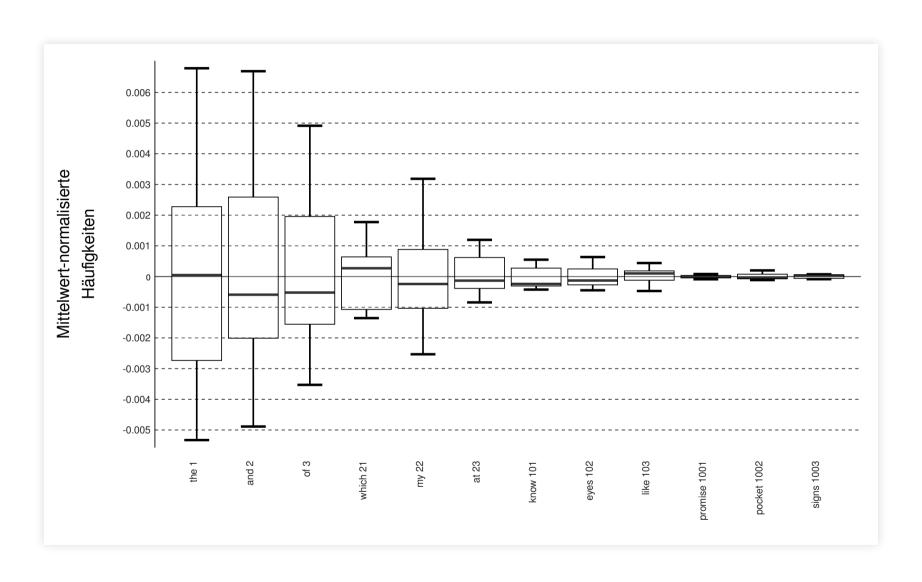
Standardisierung (z-scores)

	А	В	С	D	E
1		CorneilleP_tc0189	CorneilleP_tc0196	CorneilleT_tc0222	CorneilleT_tc0226
2	de	0.1499078729	0.8217586551	-0.3331864738	-1.7420165683
3	et	1.0217971305	1.0964111031	-0.8387654541	0.5277370396
4	vous	1.0822091538	-0.0095321888	-0.3949890303	-1.4736226833
5	le	-1.1206678643	-0.564008828	1.0248706909	1.3948544851
6	à	0.0566725616	1.5330493833	0.1440306397	0.4466104298
7	I	-0.0511188533	-0.7711812699	0.3388768906	1.809793959
8	que	0.7078952579	0.4265714426	1.0014802499	-0.7190026979
9	je	0.6485348916	-1.0497791904	-0.6054842445	-0.9991365133
10	il	0.130171823	-0.3401876567	0.6933373022	0.9600301165
11	un	0.085296816	0.2981974348	-0.5173518384	1.1003032917
12	la	-1.3921359502	1.2926652024	0.463848695	-0.016270901
13	en	0.8709978874	0.4567116762	0.3178923923	0.8031463153
14	qu	0.4674217721	0.2499659708	0.8834356711	0.767561794
15	les	-0.1311125667	0.9118507863	-0.5286288566	-1.508465172
16	d	0.409098182	0.5848113394	-0.6048980286	1.1824532584
17	est	0.0688622182	-0.758505175	1.6908155061	0.5701466176

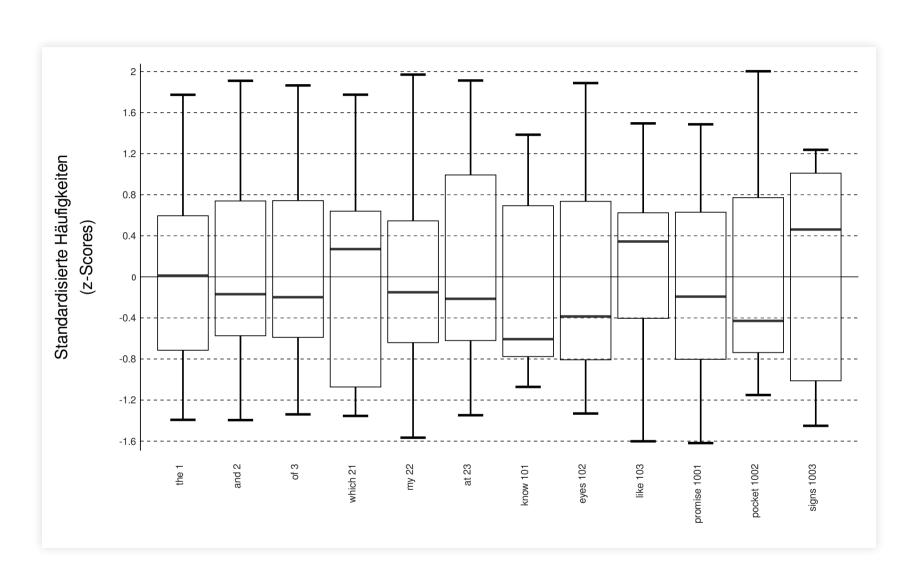
Relative Häufigkeiten



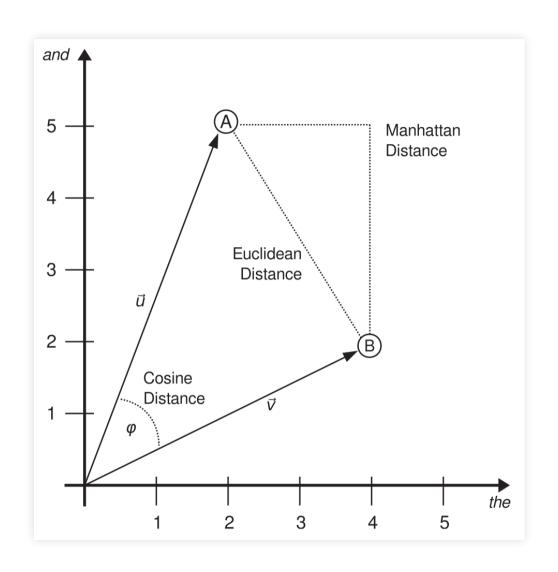
Mittelwert-Normalisierung



Z-Scores (Standardisierung)



Distanzmaße



(Quelle: Digital Humanities: eine Einführung)

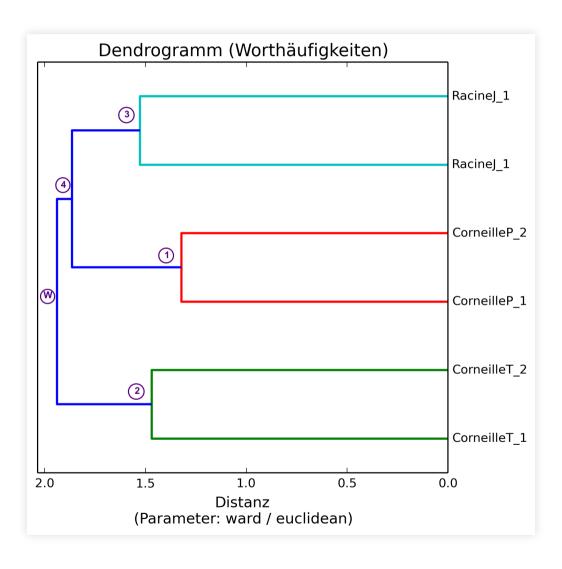
Distanz-Matrix

	А	В	С	D
1		CorneilleP_tc0189	CorneilleP_tc0196	CorneilleT_tc0222
2	CorneilleP_tc0189	0	0.9322543628	1.1478155331
3	CorneilleP_tc0196	0.9322543628	0	1.1417180795
4	CorneilleT_tc0222	1.1478155331	1.1417180795	0
5	CorneilleT_tc0226	1.1997307538	1.1472409053	1.0782741957
6	RacineJ_tc0656	1.1122630299	1.1522653374	1.1985345423
7	RacineJ_tc0661	1.2173503293	1.1504941657	1.1887585769

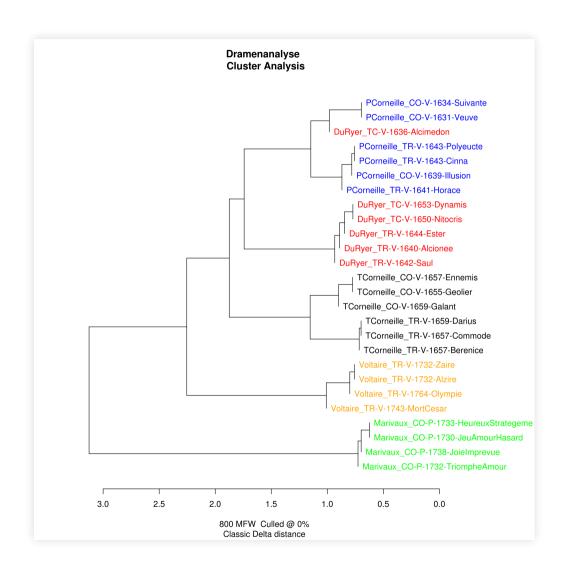
Linkage Matrix

Ast1	Ast2	Distanz	Knoten
CorneilleP_1	CorneilleP_2	1.321	Cluster 1
CorneilleT_1	CorneilleT_2	1.469	Cluster 2
RacineJ_1	RacineJ_2	1.527	Cluster 3
Cluster 1	Cluster 3	1.865	Cluster 4
Cluster 4	Cluster 2	1.938	Wurzel (W)

Dendrogramm



Anwendungsbeispiel



(26 Theaterstücke; 5 Autoren; Vers und Prosa)

Zusammenfassung des Ablaufs

- 1. Ausgangspunkt: Textsammlung (bspw. in XML-TEI)
- 2. Vorbereitung: Text extrahieren, Tokenisierung
- 3. Relativen Häufigkeiten berechnen: => Merkmals-Matrix (Text als Wortvektor)
- 4. Feature-Auswahl: bspw. Anzahl der häufigsten Wörter
- 5. Feature-Skalierung (bspw. z-scores): => skalierte Merkmals-Matrix
- 6. Anwendung eines Distanz-Maßes: => Distanz-Matrix
- 7. Transformation in eine hierarchische Struktur durch Cluster Analyse: => Linkage Matrix
- 8. Visualisierung der Linkage Matrix: => Dendrogramm
- 9. Interpretation des Dendrogramms: => Aussage

Abschluss

Lektürehinweise

Referenzlektüre

• Christof Schöch, "Quantitative Analyse", in: *Digital Humanities*: Eine Einführung. Hrsg. von Fotis Jannidis, Hubertus Kohle, Malte Rehbein. Stuttgart: Metzler.

Weitere Empfehlungen

- Jannidis, Fotis (2010). "Methoden der computergestützten Textanalyse". Methoden der literatur- und kulturwissenschaftlichen Textanalyse, hrsg. von A. Nünning und V. Nünning. Stuttgart & Weimar: Metzler, S. 109–32.
- Alpaydin, E. (2010). Introduction to Machine Learning. 2nd ed. Cambridge, Mass: MIT Press.
- Ramsay, Stephen (2011). Reading Machines: Toward an Algorithmic Criticism. Urbana III.: University of Illinois Press.

Christof Schöch, 2021 http://www.christof-schoech.de

Lizenz: Creative Commons Attribution 4.0